

딥러닝 기반의 지폐 일련번호 인식에 관한 연구

윤은수, 정대식*

상명대학교 융합전자공학전공,

상명대학교 융합공과대학 SW융합학부*

e-mail : hkhk0331@gmail.com, jungsoft97@smu.ac.k*

A Study on deep learning based banknote serial number recognition

Eunsu Yun, Daesik Jeong*

Dept. of Converged Electronics Engineering, Sangmyung University

Dept. of Faculty of SW Convergence, College of Convergence Engineering, Sangmyung University*

Abstract

본 논문에서는 전 세계적으로 줄어들고 있는 실물 지폐 사용에도 불구하고, 여전히 중요한 역할을 수행하고 있는 지폐 일련번호 인식에 대한 방법을 연구하고자 한다. 이를 위해 CRNN(Convolutional Recurrent Neural Network) 기반의 방법을 제안한다. 러시아 루블(RUB) 지폐의 다양한 권종에 대한 이미지와 일련번호를 수집하고, 이를 통해 모델을 학습시킨다. 데이터 전처리 과정에서는 가우시안 노이즈를 추가하여 데이터 증강을 적용하고, 이미지 크기 조정 및 정규화를 통해 모델의 학습 효율성을 높인다. 모델은 ResNet 기반의 CNN과 BiLSTM 기반의 RNN을 결합하여 특징 추출 및 시퀀스 예측을 수행하고, CTC Loss 함수와 Adadelata 옵티마이저를 사용하여 학습한다. 실험 결과, 모델은 99.15%의 높은 전체 정확도를 도출하였다.

I. 서론

전 세계적으로 전자적 결제 수단의 확대에 따라 지폐의 사용이 감소하고 있음에도 불구하고, 실물 지폐는 여전히 글로벌 시장에서 필수적인 역할을 수행하고 있다[1]. 일상생활에서 지폐는 가장 흔한 결제 수단 중 하나로 남아있으며, 대규모 금융 거래에서의 안전성과

효율성을 위해 ATM, 지폐 분류기와 같은 자동화된 기계의 사용이 필수적이다. 이런 기계들은 단순히 지폐를 분류하고 처리하는 것뿐만 아니라, 지폐 인식, 위조 여부 판별, 대량 일괄 처리 등의 복잡한 기능을 수행한다[2]. 이를 위해 지폐 인식, 위조지폐 검출, fitness 분류, 일련번호 인식 기능이 필수적이다[3]. 지폐의 일련번호는 각 지폐에 고유하게 새겨진 영문과 숫자의 조합으로, 일반적으로 9~11자로 구성된다[4]. 지폐의 고유한 일련번호 인식은 해당 지폐에 대한 출처 및 유통 경로를 추적하는 데 사용할 수 있어 위조 방지, 분실된 지폐의 추적, 금융 시장의 안정성 향상에 중요한 역할을 한다[5].

지폐 일련번호 인식은 광학 문자 인식(Optical Character Recognition, OCR) 알고리즘을 활용하며, 빠른 속도와 높은 정확도가 요구된다[6]. 본 논문에서는 CRNN(Convolutional Recurrent Neural Network)[7]을 사용하여 지폐의 일련번호를 인식하는 방법을 제안한다.

본론에서는 사용된 데이터 세트, 데이터의 전처리 과정, 실험 환경 및 모델에 대한 실험 결과를 기술한다. 결론에서는 연구 결과를 요약하고, 향후 연구 방향을 제시한다.

II. 본론

2.1 데이터 세트

본 논문에서 지폐 일련번호 인식을 위해 활용한 데이터 세트는 A사 ATM기의 Bill Validator에서 취득한 러시아 루블(RUB) 지폐 이미지이다. 데이터 세트에는 RUB 50, 100, 200, 500, 1,000, 2,000, 5,000루블 지폐가 포함된다. 표 1은 각 지폐 권종별 이미지의 개수를 나타낸다.

| 지폐 권종 | 개수 |
|-------|-------|
| 50 | 498 |
| 100 | 1,360 |
| 200 | 600 |
| 500 | 557 |
| 1,000 | 891 |
| 2,000 | 1,358 |
| 5,000 | 1,235 |
| 합계 | 6,499 |

표 1. RUB 지폐 권종별 개수

각각의 지폐에는 그림 1과 같이 왼쪽 하단과 오른쪽 상단 두 곳에 일련번호가 위치한다. 각 지폐에서 일련번호 영역을 Crop 하여 총 12,998장의 일련번호 이미지를 학습 데이터로 사용하였다.



그림 1. RUB 지폐의 일련번호

2.2 데이터 전처리

데이터 세트를 학습 데이터로 사용하기 위해서 각 이미지에 대해 데이터 라벨링을 진행하였다. 러시아 루블(RUB) 지폐에서 사용되는 일련번호는 특수 문자인 키릴 문자를 포함하는데, 이를 올바르게 라벨링 하기 위해 라벨링을 수동으로 진행하였다. 그림 2의 lookup table[2]을 참고하여 각 이미지에 대해 일련번호 값을 txt 파일로 저장하였다.

| 알파벳 | A | B | C | D | E | F | G | H | I | J | K | L | M | N | O | P | Q | R | T | X |
|--------|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 키릴 대문자 | А | В | С | Ь | Е | Э | З | Н | Ч | Б | К | Г | М | И | О | П | Л | Я | Т | Х |
| 키릴 소문자 | а | в | с | ь | е | э | з | н | ч | б | к | г | м | и | о | п | л | я | т | х |

그림 2. RUB lookup table

학습 데이터 세트 구성은 train set 80%, validation set 10%, test set 10% 비율로 분할하였고, 한 지폐에서 추출된 두 개의 일련번호는 동일한 세트로 나누었다. 클래스는 숫자 10개와 알파벳 20개를 포함하여 총 30개로 구성된다.

데이터 세트의 다양성을 확장하고, 모델의 정확도를 높이기 위해 train set에 데이터 증강을 적용하였다[8]. 그림 3과 같이 가우시안 노이즈(Gaussian Noise)를 추가하여 새로운 이미지를 만드는 방안을 이용하였다. 기존 이미지에 SNR을 7-10 범위의 랜덤한 값으로 설정한 가우시안 노이즈를 추가하여, 추가 이미지를 생성하였다.



그림 3. 데이터 증강 적용 예시

마지막으로 학습 이미지 크기를 100(width)×32(height)로 조정하였으며, 픽셀값의 범위를 -1과 1 사이로 정규화하여 모델의 학습 효율성을 높였다.

2.3 실험 환경

본 논문에서 제시하는 방법은 크게 세 단계로 구성된다. 그림 4는 전체 모델 구조를 나타낸다.

첫 번째 단계는 ResNet 기반의 CNN을 사용하여 입력 이미지로부터 특징 시퀀스를 추출하는 것이다. 사용한 ResNet 네트워크[9]는 다수의 컨볼루션 레이어와 풀링 레이어를 거쳐 이미지로의 핵심적인 시각적 특징을 추출한다. ResNet은 깊은 신경망에서 발생할 수 있는 기울기 소실 문제를 해결하기 위해 도입된 잔차 학습(Residual Learning) 개념을 활용하여 성능을 향상한다. 이를 통해 네트워크는 더 깊게 구성될 수 있으며, 깊이에 비례하여 정확도를 증가시킬 수 있다. 최종적으로 얻은 512채널의 특징을 시퀀스 형태의 특징으로 변환하여 다음 단계로 전달한다.

두 번째 단계에서는 BiLSTM(Bidirectional Long Short-Term Memory)[7] 기반의 RNN을 통해 이미지 내의 컨텍스트 정보를 반영한 시퀀스를 예측한다. BiLSTM은 순방향 및 역방향 정보를 모두 고려하여 정보를 추출하고, 이를 통합하여 더욱 정확한 컨텍스트 정보를 제공하여 예측의 정확도를 향상한다.

마지막으로 BiLSTM 레이어를 통해 얻은 256채널의 특징은 선형 계층으로 전달되어 모델의 최종 예측이 수행된다. 선형 계층은 입력과 가중치 행렬 간의 행렬 곱셈을 수행하고, 선택적으로 편향을 추가하여 각 클래스에 대한 점수를 제공한다. 선형 계층을 통해 변환된 점수를 Softmax 활성화 함수를 통해 확률로 변환하여 최종 예측이 이루어진다.

Loss 함수로는 CTC(Connectionist Temporal Classification)[10]를 사용하여 출력 시퀀스와 실제 레이블 사이의 비교를 통해 모델을 학습한다. CTC는 출력 시퀀스와 실제 레이블 사이의 최적 경로를 찾아내어 모델이 중복 문자나 불필요한 공백을 인식하지 않도록 하여, 모델이 더욱 정확하게 동작하도록 한다. CTC 계산을 위해 모델 입력 시 라벨은 인코딩 처리된다. 이 과정에서 텍스트 라벨을 인덱스 형태로 변환하며, CTC 공백 및 패딩을 위해 '0'을 사용한다. 최종적으로 모델의 Prediction 레이어를 통해 나온 결과는 각 문자에 대한 확률 분포이며, 해당 결과는 확률이 가장 높은 인덱스로 변환된다. 디코딩 시 연속된 문자와 CTC 공백이 제거되어 출력 텍스트를 생성한다.

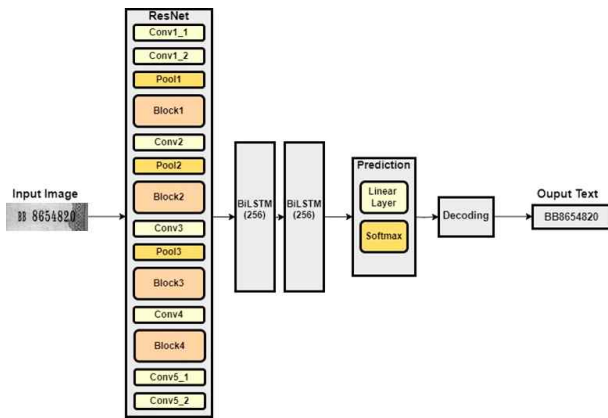


그림 4. 전체 모델 구조


옵티마이저(Optimizer)는 Adadelata[11]를 사용하였다. Adadelata는 기존 경사 하강법의 단점을 극복하고, 각 매개변수의 최근 변화량에 따라 학습률을 적응적으로 조정하는 최적화 방법으로, 깊은 네트워크에서 발생할 수 있는 학습률의 미세 조정 문제를 해결하는 데 유용하다. Rho 0.9, Epsilon 1e-08로 설정하였고, Batch Size 64, Iteration 3250으로 지정하여 학습을 진행한 후, 성능을 측정하였다.

2.4 실험 결과


test set으로 모델의 성능을 측정하였다. 정확도 측정 시 인식 실패는 예측 결과가 Ground Truth(GT)와 불일치하는 경우를 말한다. 그림 5는 인식 성공 경우와 인식 실패 경우를 보여준다.

실험 결과, 모델의 전체 정확도는 99.15%로 측정되어 높은 인식 정확도를 보였다. 또한, 문자 단위의 정확도 분석에서 대부분의 문자에 대해 높은 인식 정확도를 나타내었다. 표 2는 문자별 정확도를 나타낸 것이다. 특히 숫자 '0'에서 '9'까지는 100%의 정확도를 기록하

였다. 그러나 알파벳 'C', 'F', 'H', 'K', 'N', 'Q', 'R'은 비교적 낮은 정확도를 보였다.



(a)



(b)

그림 5. 실험 결과 예시 :

(a) 인식 성공 경우, (b) 인식 실패 경우

| Character | Accuracy | Character | Accuracy |
|-----------|----------|-----------|----------|
| 0 | 100.00 | F | 98.08 |
| 1 | 100.00 | G | 100.00 |
| 2 | 100.00 | H | 98.21 |
| 3 | 100.00 | I | 100.00 |
| 4 | 100.00 | J | 100.00 |
| 5 | 100.00 | K | 98.68 |
| 6 | 100.00 | L | 100.00 |
| 7 | 100.00 | M | 100.00 |
| 8 | 100.00 | N | 98.65 |
| 9 | 100.00 | O | 100.00 |
| A | 99.78 | P | 100.00 |
| B | 100.00 | Q | 97.14 |
| C | 98.39 | R | 97.06 |
| D | 100.00 | T | 100.00 |
| E | 100.00 | X | 100.00 |

표 2. 문자별 정확도

실험 결과에 따르면, 일부 문자에 대하여 비교적 낮은 정확도 수치를 기록하였으나 전체 정확도가 매우 높아 일련번호 인식에서 모델이 상당히 높은 성능을 보이는 것으로 확인되었다. 문자별 정확도는 향후 모델 성능 개선에 있어 중요한 결과이며, 특히 인식률이 낮게 나타난 특정 문자들에 대해서는 추가적인 연구가 필요할 것으로 보인다.

III. 결론

본 논문에서는 CRNN을 기반으로 한 지폐 일련번호 인식 방법을 제안하고, 러시아 루블(RUB) 지폐를 대상

으로 실험을 수행하였다. 연구 결과, 제안된 모델은 99.15%의 높은 전체 정확도를 보여, 지폐 일련번호 인식 방법의 성능을 입증하였다. 특히, 숫자 인식에서는 100%의 정확도를 달성하였으나, 일부 알파벳 문자에서는 비교적 낮은 정확도를 보여 향후 개선의 필요성을 나타낸다.

실험 결과에서 나타난 그림 5의 인식 실패 경우를 근거로 볼 때, 현재의 방법은 영상 분석을 통한 문자 영역의 구분이 일부 경우에 명확하지 않다는 한계가 있다. 향후에는 지폐 이미지의 해상도가 문자 인식 정확도에 미치는 영향을 조사하고, 주파수 영역 포함한 영상 개선 방법을 개발함으로써, 모델이 더 정확하게 문자를 인식할 수 있도록 하는 추가 연구를 진행할 예정이다.

참고문헌

- [1] Kim E, & Turton T. "The Next Generation Banknote Project.", RBA Bulletin, 2014, pp.1-11
- [2] 장우혁, "딥러닝 기반의 다국적 지폐 일련번호 인식 기술에 대한 연구", 2022
- [3] Lee JW, Hong HG, Kim KW, & Park KR. "A Survey on Banknote Recognition Methods by Various Sensors.", Sensors. 2017; 17(2):313, 2017
- [4] Bruna A, Farinella GM, Guarnera GC, & Battiato S. "Forgery detection and value identification of Euro banknotes.", Sensors. 2013; 13(2):2515-2529, 2013
- [5] Jang W, Lee C, Jeong DS, Lee K, & Lee EC. "Multi-Currency Integrated Serial Number Recognition Model of Images Acquired by Banknote Counters.", Sensors. 2022; 22(22):8612, 2022
- [6] Lin Z, He Z, Wang P, Tan B, Lu J, & Ba Y. "SNRNet: A Deep Learning-Based Network for Banknote Serial Number Recognition", Neural Process Letters 52, 2020, pp.1415-1426
- [7] Shi, B., Bai, X., and Yao, C. "An End-to-End Trainable Neural Network for Image-based Sequence Recognition and Its Application to Scene Text Recognition", arXiv:1507.05717v1, 2016
- [8] 김영준, 김여정, 이인선, 이흥주. "데이터 증강을 통한 딥러닝 기반 주가 패턴 예측 정확도 향상 방안", 한국빅데이터학회지 v.4 no.2, 2019, pp.1-12
- [9] Cheng Z, Bai F, Xu Y, Zheng G, Pu S, & Zhou S. "Focusing Attention: Towards Accurate Text Recognition in Natural Images", ICCV, 2017, pp.5086-5094
- [10] Graves A, & Gomez F. "Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks", ICML, 2006, pp.369-376
- [11] Zeiler M.D. "ADADELTA: An Adaptive Learning Rate Method", arXiv:1212.5701, 2012