

메모리 기반 세그멘테이션 네트워크를 활용한 지폐 정사 판단 시스템

배희재, *정대식

상명대학교 융합전자공학과 학사과정

*상명대학교 융합공과대학 SW융합학부 교수

e-mail : baehj100@naver.com, *jungsoft97@smu.ac.kr

A system for determining banknote fitness sorting using
MemSeg(memory-based segmentation network)[1]

Hee-Jae Bae, *Dae-Sik Jung

Dept. of Converged Electronics Engineering, Sangmyung University, Seoul

*Dept. of Faculty of SW Convergence, College of Convergence
Engineering, Sangmyung University, Seoul

요약

본 논문은 국가별 중앙은행의 주관적인 정사 분류 기준에 의해 발생할 수 있는 문제점을 극복하기 위해 MemSeg를 활용한 지폐 정사 판단 시스템을 제안한다.

이 시스템은 (1)지폐 입력, (2)지폐 영상 취득, (3)Skew 보정 전처리 및 권종 인식, (4)MemSeg 모델 학습, (5)지폐 부적합 정도 예측으로 구성된다. 본 논문에서 약 5800개의 데이터셋 중 모델 학습에 약 4000장 정도, Test에 약 1800장 정도 사용한 결과 평균적으로 AUROC-image는 약 82%가 나오고, AUROC-pixel는 약 54%가 나온 것을 확인할 수 있었다.

I. 서론

국가별 중앙은행의 주관적인 정사 분류 기준에 의해 발생할 수 있는 문제점들을 극복하기 위해서 지폐 영상에서 파악되는 Anomaly features를 MemSeg 방식으로 파악하여, 보다 객관적인 지폐 정사 분류 방법을 제안하고자 한다.

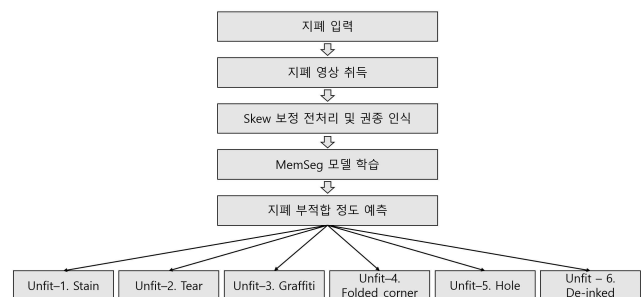


그림 1. System 개요

들어가기에 앞서 그림 1을 참고하여 시스템 개요[5]에 대해 간략히 설명하려 한다.

1-1. 지폐 입력

본 연구에서는 A사의 지폐를 분당 800매 이상 처리가 가능한 ATM기에서 러시아 루블 지폐를 투입하였다.

1-2. 지폐 영상 취득

투입된 지폐는 ATM기 내부에 고속 이미지 취득 센서(Contact Image Sensor)를 거쳐서 영상을 생성하였다. 취득이 가능한 영상 종류는 RGB 채널의 가시광 반사, 적외선 반사, 적외선 투과 영상이다. 본 연구에서는 정사 분류의 특징을 가장 잘 추출하는 가시광 반사 영상을 취득해서 사용하였다.

1-3. Skew 보정 전처리 및 권중 인식



그림 2. Skew 보정 전처리 과정

그림 2의 (a)는 가시광 반사로 취득한 영상의 크기가 864*448(Pixel size)인 Gray intensity scale 영상이다. 학습하는 과정에서 계산량을 줄이기 위해서 영상의 크기가 620*275(Pixel size)인 (b)로 축소해서 사용하였고, (c)와 같은 형태로 전처리를 완료하였다. 이후 (c) 영상을 가지고 권중을 인식하고, 지폐의 투입 방향은 A,B,C,D로 분류하여 학습하였다.

1-4. Memseg 모델 학습

전처리된 정상 지폐에 Anomaly mask를 Texture 혹은 Structure 중에 선택하여 합성 및 생성시켜준 뒤, MemSeg[2]를 기반으로 모델 학습을 진행한다.

1-5. 지폐 부적합 정도 예측




그림 3. MemSeg기반 학습 후 결함이 예측된 영상

그림 3과 같이 MemSeg 기반으로 학습시킨 뒤 이미지의 결함이 예측되는 것을 볼 수 있다.

II. 선행연구 - MemSeg

MemSeg란 차이점과 공통점을 사용하여 이미지 표면 결함을 감지하는 준지도 방법이다. 훈련단계에서 정상 이미지와 시뮬레이션된 비정상 이미지 간의 잠재적인 차이를 명시적으로 학습하여 강력한 분류 초평면을 얻는다. 동시에 MemSeg는 인간의 기억 메커니즘에서 영감의 받아 일반 샘플의 일반 패턴을 저장한 후, 입력 샘플과 메모리 풀의 메모리 샘플 간의 유사점과 차이점을 비교해 비정상적인 영역에 대한 효과적인 추측을 제공한다. 추론단계에서는 입력 이미지의 비정상 영역을 end-to-end 방식으로 직접 판별한다. [1]




그림 4. MemSeg 개요

위 그림 4과 같이 MemSeg는 U-Net 아키텍처를 기반으로 하며 사전 훈련된 ResNet18[14]을 인코더로 사용하였다. MemSeg는 Encoder의 마지막 Output을 Up-sampling 해나가면서 점점 연결해준 후 이미지의 결함에 대한 부분을 Segmentation을 수행하는 과정으로 진행되었다. 이때 Segmentation 형태로 진행될 수 있는 이유는 인위적으로 Anomaly mask를 생성한 후 진행했기 때문에 정상 이미지와 시뮬레이션된 비정상 이미지를 비교하여 Supervised 방식으로 Segmentation을 진행할 수 있었다. 또한, 메모리 정보를 입력 이미지의 높은 수준의 특징과 완전히 융합하기 위해 MemSeg는 다중 스케일 특징 융합 모듈 (Multi-scale Feature Fusion Module)과 이상 위치의 모델정밀도를 크게 향상시킨 새로운 공간 주의 모듈을 사용하였다. 다중 스케일 특징 융합 모듈에서는 Feature 피라미드 형태[10]로 구성이 되어있고, 각 Layer마다 Coordinate Attention block[3]이 적용되었다. 이후에 가장 작은 Feature map을 갖는 Feature map을 Up-sampling해서 보다 큰 Feature map에 더해주는 형식으로 전달하고, spatial Attention에서 받은 정보를 Decoder로 전달하여 결함을 예측하는 방식으로 진행되었다.




그림 5. MemSeg의 다중 스케일 특징 융합 모듈 및 공간 주의 모듈의 시각적 자료

III. 연구 과정

본 연구는 A사에서 제공한 가시광 반사 영상 약 5800장을 사용하여 진행하였다. 데이터셋은 각 러시아 지폐의 권 종별로 1000RUB, 2000RUB, 5000RUB, 100RUB, 200RUB, 500RUB, 50RUB 이렇게 총 7개의 권 종이 있고, 그중에서 1000RUB, 5000RUB, 500RUB 는 두 가지 Type을 가지고 있다. 그리고 모든 권 중은 그림 6과 같이 각각 앞, 뒷장과 앞, 뒷장의 이미지가 180도 기울어진 이미지, 총 4가지 형태의 이미지를 모두 가지고 있다.

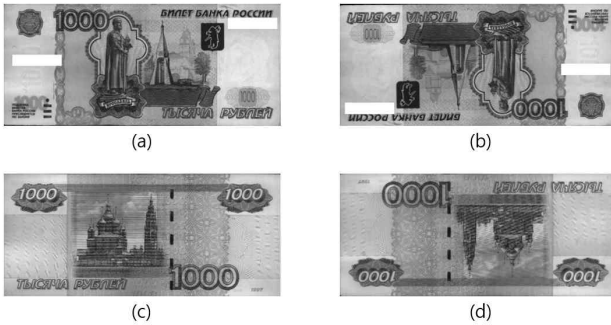


그림 6. 1000RUB의 예시 (a): 앞장, (b): 앞장 180도 회전, (c): 뒷장, (d): 뒷장 180도 회전

데이터셋을 분류하는 과정에서 러시아 중앙은행[7]의 “The Bank of Russia Notes Fitness Criteria”를 참고하여 10가지의 결함 중 아래의 표 1과 같이 Stain, Graffiti, De-inked, Hole, Tear, Folded_corner로 분류하였다.

Defect	Definition	Minimum standard
Stain	일부 영역의 얼룩이나 오염	하나의 면적이 $20mm^2$ 이상인 경우
Graffiti	그림이나 문자 (펜, 도장 등을 이용)	둘 이상의 기호, 문자, 승인되지 않은 이미지가 있을 경우
De-inked	일부나 전체 영역 잉크 탈색	잉크가 부족하다는 것을 육안으로 확인할 수 있는 경우
Hole	지폐 내부의 구멍	하나의 직경이 4mm 이상, 면적이 $12mm^2$ 이상인 경우
Tear	테두리 부분의 찢어짐	찢어진 부분의 길이가 7mm 이상인 경우
Folded_corner	귀 접힘	하나의 면적이 $32mm^2$ 이상인 경우

표 1. 러시아 중앙은행의 각 결함별 기준 목록

3.1 데이터셋 전처리

먼저 주어진 데이터셋에서 지폐 영상의 영역만 불러오기 위해 ROI(Region of Interest) 검출 과정[6]을 수

행하였다. ROI 검출 과정은 다음과 같다. (i) 임계값을 이용해 지폐 영상 영역을 분리해낸 뒤 (ii) 윤곽선 검출 필터와 허프 변환을 통해 지폐 영상의 모서리를 알아낸다. (iii) 지폐 영상의 기울어진 각도를 이용해 측정 과정을 진행하여 기울어진 입력 지폐를 측에 정렬된 상태로 만들어준다.

이외에도 유로화에는 위폐방지를 위해 지폐에 고유 일련번호가 존재한다. 공통점과 차이점을 비교하여 지폐의 결함을 검출하기 위해서는 지폐의 일련번호를 가지고 연구를 진행해야 한다. 따라서 그림 6 의(a)와 (b)처럼 각 권 종별 일정 위치에 존재하는 고유 일련번호를 Mask 처리하여 전처리를 완료하였다.

3.2 MemSeg 실험 진행

앞서 얘기한 MemSeg를 기반으로 Target을 각 권종별로 지정하고, 그중에서 Type이 2개였던 1000RUB, 5000RUB, 500RUB 또한 Type을 나누어 모델을 학습하였다. 이때 학습에 필요한 Parameter를 Batch size는 8, Memory_bank_sample은 30, Iteration은 5000, Learning_rate는 0.001로 통일시켜 학습을 진행하였다. Loss 값으로는 L1 loss와 Focal loss 값을 사용하였으며, 성능평가 지표는 AUROC_image와 AUROC_pixel로 나타내었다. 여기서 AUROC_image는 Image 단위로 분류 성능을, AUROC_pixel은 Pixel 단위로 분류 성능을 의미한다.

3.3 Demo




그림 7. MemSeg의 데모 영상 (Stain)

그림 7과 같이 MemSeg를 기반으로 학습시킨 Model에 대한 Demo 영상을 출력해보았다. 이때, 제공받은 Ground_truth가 없어 직접 히스토그램 정규화 후 OTSU 알고리즘을 이용해서 비슷한 Ground_truth를 구현해보았다. 그림 7에 있는 ‘Input X Predicted Mask’는 Predicted Mask 이미지를 투명도를 0.5로 설정하고 input 이미지를 1의 가중치를 주어 합성한 결과를 나타낸 것이다.

IV. 연구 결과

target	dataset (trainset / testset)	AUROC- image	AUROC- pixel
1000RUB (T3)	(423 / 164)	0.841	0.463
1000RUB (T4)	(417 / 178)	0.826	0.471
2000RUB	(546 / 234)	0.713	0.554
5000RUB (T1)	(377 / 164)	0.931	0.622
5000RUB (T4)	(453 / 194)	0.888	0.755
100RUB	(417 / 178)	0.756	0.674
200RUB	(422 / 180)	0.724	0.291
500RUB (T3)	(111 / 47)	0.914	0.434
500RUB (T4)	(417 / 178)	0.728	0.382
50RUB	(400 / 202)	0.889	0.739

표 2. 각 권 종별 학습 결과

표 2는 각 권종에 대한 데이터셋의 개수와 AUROC-image, AUROC-pixel을 나타낸 성능 결과이다. 각 Target 별 AUROC-image의 평균을 계산해보았을 때 약 82%가 나오고, AUROC-pixel의 평균은 약 54%가 나온 것을 확인할 수 있었다.

V. 결론

MemSeg란 차이점과 공통점을 사용하여 이미지 표면 결함을 감지하는 준지도 방법이다. 연구를 통해 러시아 지폐 일부 권종의 훼손된 부분을 비교적 우수하게 예측하는 것을 볼 수 있었고, 이를 통해 지폐 정사 판단을 보다 객관적으로 수행할 수 있다고 판단된다.

성능이 평균적으로 각각 AUROC-image는 약 82%, AUROC-pixel은 약 54%와 같이 나온 이유는 데이터셋과 Ground_truth의 문제라고 생각된다. 그 이유는 데이터셋의 분류 과정에서 결함의 종류가 2개이거나 3개, 6개 등 결함의 종류가 다 제각각이었고, 데이터셋 부족 문제도 있었다. 또 De-linked 같은 결함의 경우, 다른 결함들에 비해 결함의 정도가 선명하지 않아 잘 예측되지 않은 것을 확인할 수 있었다. 이것이 성능평가에 반영되어 낮은 성능이 나온 것이라고 생각된다. 또, Ground_truth 관련해서는 제공받은 데이터가 없어 임의로 만든 Ground-truth를 가지고 성능을 평가하다 보니 별로 좋지 않은 성과가 나타난 것으로 생각된다.

향후 A사로부터 Ground_truth를 제공받은 뒤 MemSeg를 기반으로 모델을 학습시키면 더 좋은 결과가 나올 것이라고 예상해볼 수 있다.

참고문헌

- [1] Minghui Yang, Peng Wu, Liu, and Hui Feng, MemSeg: A semi-supervised method for image surface defect detection using differences and commonalities, CoRR, abs, 2205.00908, 15p, 2022
- [2] <https://github.com/TooTouch/MemSeg>
- [3] Q. Hou, D. Zhou, and J. Feng, Coordinate attention for efficient mobile network design, IEEE/CVF, pp. 13713-13722, 10p, 2021.
- [4] Paul Bergmann, Kilian Batzner Michael Fauser, David Sattlegger, Carsten Steger, The MVTec Anomaly Detection Dataset: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection, IEEE/CVF - CVPR, 22p, 2019
- [5] 고희일, 정대식, 김성일, 이은경, 이지우, 조달호, 윤성수, 이일병, 기계학습을 이용한 지폐 정사 분류 시스템, 한국컴퓨터종합학술대회, 3p, 2013
- [6] 박서현, CIS 지폐 영상을 이용한 지폐 적합도 감별 기법, 서울대학교 석사학위논문, 51p, 2012
- [7] <https://www.cbr.ru/eng/>
- [8] Tuyen Danh Pham, Dat Tien Nguyen, Wan Kim, Sung Ho Park, Kang Ryoung Park, Deep Learning-Based Banknote Fitness Classification Using the Reflection Images by a Visible-Light One-Dimensional Line Image Sensor, MDPI, 19p, 2018
- [9] T. W. Tang, W. H. Kuo, J. H. Lan, C. F. Ding, H. Hsu, and H. T. Young, Anomaly detection neural network with dual auto-encoders GAN and its industrial inspection applications, Sensors, vol. 20, no. 12, pp. 3336, 2020
- [10] N. Cohen and Y. Hoshen, Sub-image anomaly detection with deep pyramid correspondences, arXiv preprint arXiv:2005.02357, 2020
- [11] Jaehyeok Bae, Jae-Han Lee, Seyun Kim, PNI : Industrial Anomaly Detection using Position and Neighborhood Information, arXiv preprint arXiv:2211.12634, 2023